

TransGrokking M1 当前实验结果可视化报告

Canonical run: 20260721T045433955396Z_30c62ebc | 400 个原始 evaluation 点 | step 50-20000

100 t_fit	6050 t_grok50	7000 t_grok99	98.97% Final test accuracy
--------------	------------------	------------------	-------------------------------

1. 数据来源与范数约定


报告数据来自仓库 results/m1_ce_reference/, 结果提交为 98abdc6997ccf26bccc38583d7242f85187da9d6。provenance.json 记录 canonical run、scientific config hash、split hash、400 个 evaluation 点和原始 scalars SHA-256。所有 CSV 均保留原始 step，没有平滑、插值或重采样。

参数范数采用欧氏 L2 范数。对参数集合 S ： $\|\theta_S\|_2 = \sqrt{\sum_{p \in S} \sum_i p_i^2}$ 。矩阵和高阶参数张量展平后计算，数值等价于 Frobenius 范数。平方和使用 FP64 累加，范围只包含可训练模型参数；optimizer state 不参与。


字段	参数集合	范数
parameter_norm_total	全部可训练参数	全局欧氏 L2
parameter_group_norm_decay	矩阵权重与 embeddings	分组欧氏 L2
parameter_group_norm_no_decay	bias 与 LayerNorm	分组欧氏 L2
parameter_norm_<module>	互不重叠的模块参数	模块 L2 / 张量 Frobenius

报告未使用谱范数、算子范数或平方 L2 值。正式模型 final_norm=false，parameter_norm_final_norm 在 CSV 中为空值。


2. Accuracy：延迟泛化与反复失稳




训练集在 step 100 首次超过 0.999。测试准确率到 step 6050 达到 70.40%，step 7000 首次超过 99%。后续多次出现 train/test 同步坍塌，最终 step 20000 的 test accuracy 为 0.989727。 t_{fit} 与 t_{grok99} 记录首次连续阈值窗口，无法单独表示永久拟合或稳定泛化起点。



3. Cross-entropy loss



早期 train CE 快速下降，test CE 长期维持高值。step 5800 的 test CE 为 13.679，step 6050 降至 0.823，step 7000 降至 0.0481。准确率坍塌位置同时出现 train/test CE 尖峰。




对数纵轴展示低损失区间。两张图使用同一组 400 个原始 evaluation 点。

4. Margin：分类边界的行为层证据

单样本 margin 定义为正确类别 logit 减去最大错误类别 logit。margin>0


表示该样本分类正确。下图展示五个关键检查点的均值及 q05-q95 区间；完整 400 点曲线已提交为 figures/margin_train.svg 与 figures/margin_test.svg。




Step	Train mean	Test mean	Test q05	Test q95
50	-0.551	-4.918	-7.492	-2.574
5800	7.454	-13.229	-31.548	-0.505
6050	2.819	0.720	-2.291	3.181
7000	6.671	4.711	1.911	6.729
20000	6.032	5.459	3.040	6.981

step 5800 时训练 margin 已显著为正，测试 mean margin 仍为 -13.23。step 6050 的测试 mean margin 转为正值，随后与测试准确率共同上升。最终 test mean margin 为 5.459，test min margin 为 -4.813，q01 为 -0.0325。

5. 参数 L2 / Frobenius 范数




全局参数 L2 从 step 50 的 117.65 降至 step 20000 的 37.02。Decay group L2 从 115.24 降至 18.01；no-decay group L2 从 23.69 升至 32.35。两组互不重叠，满足 $||\theta_{total}||_2^2 = ||\theta_{decay}||_2^2 + ||\theta_{no_decay}||_2^2$ 。



Token embedding 的 Frobenius/L2 从 109.20 降至 2.20，position embedding 从 16.06 降至 0.19。Block 0/1 LayerNorm 的 L2 分别从 16.61/16.71 增至 20.03/24.79。该组间重分配与 weight decay 策略一致，其功能含义需由 M2 和后续优化动力学分析检验。

完整 400 点参数范数曲线位于 `parameter_norm_curve.csv`；完整图位于 `figures/parameter_norm_groups.svg` 与 `parameter_norm_modules.svg`。

6. 多次性能坍塌



Step	Train acc.	Test acc.
1400	0.0345	0.0027
3450	0.0194	0.0057
5850	0.0213	0.0064
7350	0.0247	0.0163
8450	0.1544	0.1116
10050	0.0834	0.0733
12350	0.2687	0.2163
14250	0.0186	0.0145
15350	0.0271	0.0289
17500	0.0651	0.0484
18350	0.0308	0.0253

这些坍塌同时出现在 train 与 test 指标中，随后能够恢复。M1 数据确认失稳事件及其时间位置；具体原因需结合函数空间指标、优化器更新分解和多 seed 复现。

7. 当前结论与下一阶段

当前数据支持	当前阶段仍待检验
seed 1 出现明显延迟泛化；训练拟合显著早于测试泛化；轨迹含算法结构形成前失稳残差精英的微扰现象；将 replay 数据重新分配	

M2 应沿同一 canonical run 重建完整中心化 logits，并生成 Reynolds 投影、D_eq、Gamma、I、t_alg 与 t_dom 时间线。多次坍塌附近的 checkpoint 应列为优先分析点。

8. 可复核文件

文件	内容
results/ml_ce_reference/scalars.jsonl	400 条完整原始 evaluation record
loss_curve.csv / accuracy_curve.csv	完整 loss 与 accuracy 时间线
margin_curve.csv	完整 train/test margin 均值、最小值和分位数
parameter_norm_curve.csv	完整全局、parameter group 与模块参数 L2 范数
provenance.json	run、hash、step、字段和无平滑声明
figures/*.svg	可缩放完整连续曲线

本 PDF 内嵌完整 400 点 loss 与 accuracy 曲线。Margin 与参数范数页展示关键检查点；对应的完整 400 点 CSV 和 SVG 已在仓库目录中版本化保存。